

Aprendizaje automático para la personalización de modelos electrofisiológicos en fibrilación auricular

P. de Luna, M. Termenon-Rivas, G. S. Romitti, D. de Luis-Moura, M. Rodrigo, A. Liberos

CoMMLab, Departament d'Informàtica, Departament d'Enginyeria Electrònica, Universitat de València, València, España
alejandro.liberos@uv.es

Resumen

La fibrilación auricular (FA) es la arritmia cardíaca más prevalente, sin embargo, los tratamientos tienen una eficacia limitada debido a la variabilidad entre sujetos. Si bien la personalización de los modelos cardíacos computacionales puede mejorar la selección de la terapia, el proceso se ve obstaculizado por costos computacionales y temporales.

Este trabajo presenta un marco de aprendizaje automático (ML) diseñado para personalizar rápidamente modelos electrofisiológicos auriculares para pacientes con FA. La metodología implicó la creación de una población virtual de 2,100 perfiles iónicos. Estos perfiles se evaluaron mediante simulaciones electrofisiológicas con rotores para determinar la capacidad de sostener actividad reentrante y los biomarcadores de reentrada. Posteriormente, se entrenaron una serie de modelos de ML, para clasificar la capacidad de mantener la reentrada, y para predecir los valores de los biomarcadores de reentrada correspondientes directamente a partir de las configuraciones de corrientes iónicas.

Los modelos entrenados demostraron una alta precisión, con clasificadores que lograron puntuaciones F1 de 0.95. Los modelos de regresión predijeron con precisión los biomarcadores con un valor R^2 de hasta 0.97. Un caso de uso destacó la eficiencia del marco teórico, mostrando que podía identificar perfiles iónicos específicos del paciente entre 100,000 candidatos instantáneamente, una tarea que requeriría alrededor de 625 días usando simulaciones convencionales.

En conclusión, el flujo de trabajo de ML desarrollado acelera drásticamente la creación de modelos cardíacos personalizados. Al estimar comportamientos electrofisiológicos complejos en segundos, este enfoque proporciona una vía viable para integrar gemelos digitales específicos del paciente en la investigación clínica y, diseñar terapias personalizadas para la fibrilación auricular.

36% con la ablación por catéter, lo que evidencia las limitaciones de las terapias actuales.

Esta falta de eficacia se debe en parte a que los mecanismos fisiopatológicos de la FA varían entre pacientes. En consecuencia, un tratamiento que sea eficaz para un paciente podría no serlo para otro.

Para superar esta limitación, la creación de un "gemelo digital" individualizado del corazón de cada paciente emerge como una solución prometedora [2]. Este modelo computacional personalizado podría simular la respuesta del corazón a diferentes tratamientos, permitiendo así una selección de terapia más precisa y adaptada a las características únicas de cada individuo [3].

El principal obstáculo para la implementación de estos gemelos digitales es el elevado costo computacional y el tiempo requerido para la personalización de los modelos. Este proceso es tan intensivo que limita en gran medida su uso clínico y de investigación. Por lo tanto, es esencial desarrollar nuevas metodologías que reduzcan drásticamente el tiempo de creación de estos modelos personalizados, sin comprometer su precisión, para que puedan ser integrados en la práctica clínica diaria y mejorar el pronóstico de los pacientes con FA.

Es por ello por lo que, en este trabajo se van a desarrollar herramientas de inteligencia artificial que faciliten acelerar la estimación de biomarcadores de fibrilación auricular - longitud del ciclo de activación (CL) y velocidad de conducción en reentrada (CV_r) - con el ánimo de poder asignar a cada paciente y región el modelo electrofisiológico apropiado.

1. Introducción

La fibrilación auricular (FA) es la arritmia cardíaca más común, afectando a una porción significativa de la población, cuya incidencia aumenta con la edad. Mientras que su prevalencia se sitúa en un 1-2% en la población general, puede alcanzar hasta un 5% en pacientes mayores de 65 años. Esta condición se presenta como un reto clínico complejo, ya que los mecanismos que inician y mantienen la arritmia no se comprenden por completo [1].

Actualmente, existen dos enfoques principales para el tratamiento de la FA: la terapia farmacológica con fármacos antiarrítmicos y la ablación con catéter. Sin embargo, estos últimos tratamientos tienen una tasa de recurrencia considerable, lo que subraya la necesidad de estrategias más efectivas. Se ha observado que la tasa de recurrencia en el primer año es del 59% con fármacos y del

2. Métodos

2.1. Generación de la población de modelos

Se partió del modelo electrofisiológico de Koivumäki [4], que representa matemáticamente la actividad eléctrica en las células cardíacas. Este modelo, originalmente para el ritmo sinusal, fue modificado para representar la fibrilación auricular crónica (cAF) mediante la alteración de ciertas conductancias iónicas.

Para modelar la variabilidad fisiológica entre pacientes, se creó una población virtual de 2,100 perfiles iónicos. Se seleccionaron ocho corrientes iónicas clave para ser modificadas dentro de un rango de -75% a +150%. Para garantizar una representación uniforme del espacio de posibles combinaciones, se utilizó el método de muestreo latin hypercube sampling (LHS) [5].




Figura 1. Metodología empleada. (A) Se simularon distintos perfiles iónicos en eventos de reentrada, se midieron biomarcadores de reentrada CV y CL. (B) Se entrenaron y evaluaron modelos de machine learning para evaluar los perfiles iónicos que propagan [6] y reentran para finalmente predecir los biomarcadores.

2.2. Simulaciones y obtención de biomarcadores

Cada uno de los 2,100 perfiles iónicos fue evaluado mediante simulaciones electrofisiológicas para analizar su capacidad de propagar el potencial de acción y caso afirmativo se evaluó la capacidad de sostener la actividad reentrante. En estas simulaciones, se indujo un rotor para determinar este comportamiento y se midieron biomarcadores clave (como se ve en el panel A de la figura 1), como la longitud del ciclo de activación (CL), la velocidad de conducción en reentrada (CV_r).

La longitud del ciclo de activación (CL) es el tiempo transcurrido entre dos activaciones consecutivas en un punto específico.

La velocidad de conducción de reentrada (CV_r) mide la velocidad a la que el frente de onda eléctrico se propaga a lo largo de la trayectoria de reentrada. Ambos biomarcadores, se midieron directamente en las simulaciones con el rotor para determinar la capacidad de cada perfil iónico para sostener la actividad reentrante [6].

2.3. Entrenamiento y evaluación de modelos de machine learning

Se entrenaron una serie de modelos de ML con el propósito de clasificar los perfiles iónicos que mantienen la reentrada y predecir los valores de los biomarcadores (CV_r y CL) directamente a partir de las configuraciones de las corrientes iónicas. Los modelos se entrenaron utilizando técnicas de búsqueda de hiperparámetros (grid search) y validación cruzada (cross validation). Finalmente, los modelos y sus errores de predicción se evaluaron utilizando métricas como el F1-score para la clasificación y el MAE, MSE y R² para la regresión.

3. Resultados

3.1. Análisis de las propiedades electrofisiológicas

En la Figura 2A se observaron diferencias significativas en las conductancias de las corrientes iónicas entre los perfiles que eran capaces de sostener una reentrada y los que no, la prueba estadística para saber si es significativa la diferencia o no se usó el Mann-Whitney U test. Mientras que en la 2B se puede ver la correlación de esas corrientes con los

biomarcadores de aquellos modelos que sí mantienen la reentrada.

Es interesante ver como el I_{Na} está muy correlacionado con los biomarcadores de reentrada, pero no presenta diferencias significativas entre los modelos que reentran y los que no. Por otro lado podemos ver como el I_{K1} es el más correlado con el CL y además presenta importantes diferencias significativas entre los modelos que reentran y los que no.




Figura 2. (Arriba) Boxplots comparando el peso de las corrientes iónicas entre los modelos que reentran y no reentran. (Abajo) Correlación parcial entre las corrientes iónicas y los biomarcadores de reentrada.

La Figura 3 presenta el análisis de la correlación entre los biomarcadores de reentrada y los de propagación del potencial de acción. Este análisis mostró una alta correlación entre los biomarcadores del potencial de acción y los biomarcadores de reentrada.




Figura 3. Relación entre los biomarcadores de reentrada y los biomarcadores a ritmo estimulado 1Hz [6].

3.2. Evaluación de los modelos de ML

La Figura 4 detalla los resultados del rendimiento de los modelos de machine learning. Se evaluaron distintos modelos, los mejores resultados en las tres fases – clasificación de conducción o reentrada y regresión de biomarcadores- se obtuvieron con perceptrones multicapa de entre 3 y 4 capas densas. En primer lugar, una matriz de confusión muestra el rendimiento del clasificador. En las tareas de clasificación, se alcanzaron puntuaciones F1 de 0.95 para la detección de reentrada, lo que indica que el modelo es altamente fiable. Para las tareas de regresión, los modelos predijeron los biomarcadores de reentrada con un valor R2 de hasta 0.969.

3.3. Ejemplo de uso

Para explorar la aplicabilidad clínica del flujo de trabajo desarrollado, se partió de un caso concreto: un paciente del que se disponía de mediciones experimentales de CV_r=337 mm/s y CL=185 ms. Este escenario representa una situación habitual en la práctica clínica, en la que la obtención de ciertos parámetros o biomarcadores es factible, pero la las corrientes iónicas en cada paciente no son accesibles.

A partir de estos valores medidos (CV_r y CL), se empleó el modelo de aprendizaje automático entrenado previamente para inferir cuáles de las configuraciones iónicas dentro de un conjunto de 100.000 posibles modelos virtuales era capaz de propagar, reentrar y presentaban unos biomarcadores de reentrada más parecidos a los del paciente. Estas configuraciones abarcan una amplia diversidad fisiológica y patológica, y se evaluaron, sin necesidad de realizar nuevas simulaciones para el caso clínico particular.




Figura 4. Predicciones (arriba) Matriz de confusión identificación modelos que reentran, se prioriza la sensibilidad frente a la especificidad. (Abajo) Predicciones de los valores de reentrada tanto para los modelos de entrenamiento como para los de test.

El sistema clasificó rápidamente qué subconjunto de modelos iónicos presentaba un perfil electrofisiológico compatible con los biomarcadores del paciente, con estos modelos ya se podrían hacer varias simulaciones que reflejen los biomarcadores del paciente para evaluar terapias de forma simulada.

En la figura 5 se puede ver la distribución de las corrientes iónicas para los 20 modelos modelos iónicos cuyos biomarcadores predichos eran más cercanos a los del paciente (CV_r y CL). Entre aquellos modelos iónicos predichos de mayor cercanía la CV_r media es de 336.86±1.86, y la CL de data 185.17±1.67. Con esta imagen podemos concluir que modelos iónicos diferentes, pueden presentar biomarcadores similares. Anotar que estos modelos iónicos diferentes podrían responder de manera diferente a ciertos tratamientos farmacológicos. Anotar también como las corrientes I_{Na} e I_{K1} que a lo largo del trabajo han demostrado un mayor impacto en los biomarcadores presentan una menor variabilidad en este punto.

Destacar finalmente que la simulación de las 100.000 reentradas en la plataforma de simulación del grupo hubiese costado 625 días (9 minutos por simulación) mientras que la estimación con la herramienta de Machine Learning presentada es prácticamente instantánea.

4. Conclusiones

Este trabajo ha cumplido con éxito su objetivo principal: desarrollar y validar una metodología basada en aprendizaje automático (machine learning) capaz de acelerar de forma drástica el proceso de creación de gemelos digitales cardíacos. La plataforma desarrollada

supera la principal barrera para la adopción clínica de estos modelos personalizados: el elevado coste computacional y temporal asociado a las simulaciones electrofisiológicas.

La innovación fundamental reside en la capacidad del sistema para estimar de manera masiva e instantánea biomarcadores complejos, como la velocidad de conducción y las características de los circuitos de reentrada, para decenas de miles de perfiles iónicos distintos. Este avance representa un cambio de paradigma en la eficiencia: un proceso de caracterización que mediante la simulación tradicional hubiese requerido 625 días, ahora puede ejecutarse en segundos. La herramienta elimina así el cuello de botella computacional, permitiendo explorar una diversidad fisiológica y patológica a una escala previamente inabordable.




Figura 5. Distribución de las corrientes iónicas de los 20 modelos iónicos, entre 100.000, cuyos biomarcadores de reentrada reflejan mejor los biomarcadores medidos en un paciente [7].

Al desacoplar la predicción de la simulación, este enfoque permite identificar rápidamente los perfiles iónicos subyacentes que se corresponden con los biomarcadores clínicos de un paciente. Esto no solo agiliza la construcción de un modelo personalizado, sino que también aporta un conocimiento más profundo, al revelar que diferentes configuraciones iónicas pueden producir comportamientos eléctricos similares. Dicha constatación es crucial, ya que refuerza la necesidad de modelos específicos para cada individuo a la hora de evaluar, por ejemplo, la respuesta a tratamientos farmacológicos.

En definitiva, este trabajo establece una base metodológica sólida y eficiente que acelera la generación de gemelos digitales cardíacos. Al transformar un proceso de meses en una tarea instantánea, se da un paso decisivo para hacer de la simulación personalizada una herramienta viable en la investigación clínica y, en el futuro, un pilar para la estratificación de riesgo y el diseño de terapias a medida en la cardiología.

Agradecimientos

Este trabajo ha sido financiado por la Generalitat Valenciana Subvención AICO/2021/318 (Consolidables 2021), y Subvención PID2020-114291RB-I00, PID2023-148702OB-I00 y EraNet PCI2024-153442 financiada por MCIN/ 10.13039/501100011033 y por “ERDF A way of making Europe”.

Referencias

[1] I. C. Van Gelder et al. “2024 ESC Guidelines for the management of atrial fibrillation developed in collaboration with the European Association for Cardio-Thoracic Surgery (EACTS)”, European Heart Journal, 45(36), pp. 3314–3414, 2024, doi: 10.1093/eurheartj/ehae176.

[2] S. A. Niederer, M. M. Lumens et al., “Creation and application of virtual patient cohorts of heart models,” Philos. Trans. R. Soc. A., 378(2173), pp. 20200219, 2020, doi: 10.1098/rsta.2020.0219.

[3] C. H. Roney, M.L. Beach, M. L., et al. “In silico comparison of left atrial ablation techniques that target the anatomical, structural, and electrical substrates of atrial fibrillation”. Frontiers in physiology, 11, 1145, 2020. doi: 10.3389/fphys.2020.572874

[4] J. T. Koivumäki, P. Tavi y cols., “In silico screening of the key cellular remodeling targets in chronic atrial fibrillation,” PLoS Comput. Biol., 10(5), pp. e1003620, 2014, doi: 10.1371/journal.pcbi.1003620.

[5] A. Liberos, A. Bueno-Orovio, et al.”Balance between sodium and calcium currents underlying chronic atrial fibrillation termination: An in silico intersubject variability study”. Heart Rhythm., 13(12), pp. 2358-2365. doi: 10.1016/j.hrthm.2016.08.028.

[6] M. Chen Bai, G.S. Romitti, G.S., et al. “A Machine Learning Approach to the Personalization of Atrial Electrophysiological Models”. In: Computing in Cardiology 2024. DOI: 10.22489/CinC.2024.119

[7] M. Termenón-Rivas, G.S. Romitti, et al. “Electrophysiologically-Characterized Digital Twins from Intracavitary Recordings During Atrial Fibrillation”. In: Functional Imaging and Modeling of the Heart. FIMH 2025. Lecture Notes in Computer Science, vol 15672. DOI: 10.1007/978-3-031-94559-5_10